

# Predicción de churn en clientes Telco

De un problema de negocio a un ranking accionable para priorizar la retención.

**Matías Goldschmidt**



# Del problema de negocio al objetivo predictivo

## PROBLEMA

**La empresa pierde ingreso recurrente cuando un cliente abandona el servicio.**

Sin una priorización, retención distribuye tiempo y beneficios entre clientes con riesgos muy distintos.

## OBJETIVO DEL MODELO

**Estimar la probabilidad de churn de cada cliente activo.**

El resultado es un ranking de riesgo para decidir a quién contactar primero; la oferta y el corte final dependen del costo y la capacidad comercial.

**7.043**

CLIENTES · base analizada

**26,5%**

CHURN · 1.869 bajas

Retener cuesta entre 5 y 25 veces menos que captar un cliente nuevo.

# 21 columnas: 19 predictoras agrupadas en 4 familias

## Demográficas

### 4 variables

Género  
SeniorCitizen  
Partner  
Dependents.

**Asociación débil con el churn**

## Servicios

### 9 variables

PhoneService, MultipleLines,  
InternetService, OnlineSecurity,  
OnlineBackup, DeviceProtection,  
TechSupport, StreamingTV y  
StreamingMovies.

**Asociación moderada con el churn**

## Contrato

### 2 variables

Contract  
Tenure.

**Asociación muy fuerte con el churn**

## Facturación

### 4 variables

PaperlessBilling  
PaymentMethod  
MonthlyCharges  
TotalCharges.

**Asociación moderada con el churn**

**Limpieza:** los 11 vacíos de TotalCharges eran clientes nuevos (antigüedad = 0) → se imputaron en 0. Sin filas duplicadas.

# Variables nuevas: cómo se construyen y qué resumen

## VARIABLE CREADA #1

### Contrato mensual

is\_month\_to\_month = 1 si Contract es “Month-to-month”; 0 si el contrato es anual o bianual.

## VARIABLE CREADA #2

### Fibra óptica


has\_fiber\_optic = 1 si InternetService es “Fiber optic”; 0 para DSL o sin internet.

## OTRAS VARIABLES DERIVADAS

Antigüedad en 5 tramos · gasto histórico mensual y brecha de cargos · conteos de soporte, streaming y servicios · señales de pago digital

Estas features no agregan información futura: reorganizan datos disponibles al momento de predecir.

# Principales hallazgos del EDA respecto del churn



LECTURA

Cheque electrónico y contrato mensual concentran tasas cercanas al 45%.

Fibra y ausencia de soporte o seguridad superan la media general.

El contrato a 2 años presenta el churn más bajo: 2,8%.

Son asociaciones; orientan hipótesis, no prueban causalidad.



# Con clases desbalanceadas: PR-AUC compara y F2 define el corte

## PR-AUC

### ¿Qué tan bien ordena el riesgo?

Churn es la clase minoritaria (26,5%).  
Se busca evaluar específicamente qué tan bien el modelo identifica y prioriza esa clase, equilibrando recall y precisión para todos los umbrales.  
Por eso es la métrica principal para comparar modelos.

**Uso: comparar modelos bajo la misma validación cruzada.**

## F2

### ¿Dónde conviene cortar el ranking?

En retención, un falso negativo es un cliente que se va sin recibir una acción; implica perder ingreso recurrente. Un falso positivo genera un contacto u oferta posiblemente innecesaria, normalmente menos costosa. Por eso priorizamos recall; F2 le da 4 veces más peso sin ignorar precisión.

**Uso: elegir el umbral operativo dentro de train.**

# Validación confiable: estratificación, CV y test cerrado

## PARTICIÓN

**80% train · 20% test**

Split estratificado: conserva aproximadamente 26,5% de churn en ambos conjuntos. Evita que una partición azarosa distorsione la comparación.

**Seed 42 · test usado una sola vez**

## VALIDACIÓN CRUZADA

**5 folds dentro de train**

Cada combinación entrena en 4 folds y valida en el restante; el proceso rota cinco veces. Se promedian los resultados para comparar modelos e hiperparámetros con menor dependencia de un único corte.

**Misma métrica: PR-AUC**

## SIN LEAKAGE

**El test no informa decisiones**

Imputación, escalado y one-hot se ajustan dentro de cada fold. customerID queda excluido y el umbral F2 se elige con validación interna, nunca mirando el test final.

**0 clientes solapados train / test**

# Regresión logística: baseline simple, fuerte e interpretable

## BASELINE REAL

### Regresión logística

**35** variables predictoras

19 originales + 16 derivadas; tras one-hot se expanden a 65 columnas.

**Regularización L2 · C = 3,0**

## POR QUÉ SE ELIGE COMO BASELINE

Es el estándar simple para clasificación binaria y entrega probabilidades de churn.

Es rápida, reproducible e interpretable: sus coeficientes muestran dirección y peso.

La regularización L2 reduce el riesgo de sobreajuste.

Usa el mismo pipeline, variables y folds: la comparación es justa.

— Supera al Dummy y alcanza PR-AUC CV = 0,660.

## PISO


### Dummy

**PR-AUC 0,265**

Solo representa la prevalencia. Sirve para comprobar que el baseline aprende señal real.



# 10 modelos comparados por PR-AUC en validación cruzada



**Los modelos lineales y de boosting concentran el mejor desempeño. Las diferencias superiores son pequeñas: importa validar estabilidad, no solo el ranking puntual.**

**Los métodos más complejos no garantizan una mejora material. La elección debe equilibrar desempeño, interpretabilidad, costo y mantenimiento.**

# CatBoost — hiperparámetros y desempeño en test

**0,664**PR-AUC  
ranking**90,9%**RECALL  
churn detect.**42,4%**PRECISION  
contactos útiles**0,740**F2  
umbral 0,31

## Hiperparámetros (GridSearch)

depth = 4

iterations = 100


learning\_rate = 0.05

l2\_leaf\_reg = 3

Brecha train-test baja (+0,02 en F2) y sin leakage:  
ID excluido, 0 solapamiento train/test, umbral fuera del test.

|             | Predijo: No                  | Predijo: Churn               |
|-------------|------------------------------|------------------------------|
| Real: No    | <b>574</b><br>Verdadero neg. | <b>461</b><br>Falso positivo |
| Real: Churn | <b>34</b><br>Falso negativo  | <b>340</b><br>Verdadero pos. |

## El umbral 0,31 prioriza detectar a los que se van



Con umbral 0,31 se captura el 91% de los churners (recall alto).


El costo son más falsos positivos: la precisión baja a ~42%.

Decisión de negocio: mejor sobre-contactar que perder a un cliente.

Probabilidad  $\geq 0,31$ : Se predice churn y se considera al cliente para una acción de retención.

Probabilidad  $< 0,31$ : Se predice que permanecerá.

# SHAP confirma el EDA y agrega una lectura multivariable




SHAP muestra cuánto aporta cada variable a las predicciones del modelo.

**Coincide con el EDA: contrato mensual, baja antigüedad, fibra y falta de soporte/seguridad vuelven a dominar.**

**El modelo agrega matices: cargos acumulados y combinaciones entre variables ganan relevancia al analizarlas juntas.**

**Coincidencia no implica causalidad; SHAP explica predicciones, no el motivo real de la baja.**

# El modelo prioriza; negocio personaliza la intervención



## DEL SCORE A UNA ACCIÓN CONCRETA

### RIESGO ALTO: ATENCION PRIORITARIA

Score + valor del cliente definen el orden de contacto.

### SHAP: EJEMPLOS DE ACCION

SHAP permite ver qué variables influyeron en el riesgo de cada cliente. La empresa adapta la intervención según esas señales

### RIESGO BAJO: NO SOBREINCENTIVAR

Monitorear y reservar descuentos para clientes con riesgo y valor suficientes.

### MEDIR: ACCIONES FUNCIONAN?

Grupo de control · churn evitado · costo por retención · margen incremental



# Qué falta para llevarlo a una decisión productiva

## Limitaciones

- Dataset sin dimensión temporal: no simula pasado → futuro.
- No hay costos reales de contacto, oferta ni valor del cliente.
- Precisión moderada: muchos contactos no terminarían en churn.
- Variables derivadas algo redundantes con las originales.

## Mejoras

- Validar con meses futuros y monitorear drift.
- Elegir umbral por valor esperado ( $\text{prob} \times \text{valor} \times \text{costo}$ ).
- Sumar tickets, NPS, uso del servicio y promociones.
- Calibrar probabilidades para usar el score como ranking.

## 11 • CONCLUSIÓN

# Un ranking accionable para priorizar la retención

- Transformamos el problema de negocio en un modelo reproducible.
- CatBoost ordena a los clientes activos por riesgo de baja.
- Perfil de alto riesgo: contrato mensual, poca antigüedad, fibra, pocos servicios.
- Acción: contactar primero a los de mayor score con permanencia, soporte o beneficios.

**CatBoost**

MEJOR PR-AUC

**0,664**

PR-AUC TEST

**90,9%**

RECALL

Antes de producción: definir costo de acción, capacidad y umbral por rentabilidad esperada.