

Predicción de churn en clientes Telco

De un problema de negocio a un ranking accionable para priorizar la retención.

Matías Goldschmidt



Del problema de negocio al objetivo predictivo

PROBLEMA

La empresa pierde ingreso recurrente cuando un cliente abandona el servicio.

Sin una priorización, retención distribuye tiempo y beneficios entre clientes con riesgos muy distintos.

OBJETIVO DEL MODELO

Estimar la probabilidad de churn de cada cliente activo.

El resultado es un ranking de riesgo para decidir a quién contactar primero; la oferta y el corte final dependen del costo y la capacidad comercial.

7.043

CLIENTES · base analizada

26,5%

CHURN · 1.869 bajas

Retener cuesta entre 5 y 25 veces menos que captar un cliente nuevo.

21 columnas: 19 predictoras agrupadas en 4 familias

Demográficas

4 variables

Género
SeniorCitizen
Partner
Dependents.

Asociación débil con el churn

Servicios

9 variables

PhoneService, MultipleLines,
InternetService, OnlineSecurity,
OnlineBackup, DeviceProtection,
TechSupport, StreamingTV y
StreamingMovies.

Asociación moderada con el churn

Contrato

2 variables

Contract
Tenure.

Asociación muy fuerte con el churn

Facturación

4 variables

PaperlessBilling
PaymentMethod
MonthlyCharges
TotalCharges.

Asociación moderada con el churn

Limpieza: los 11 vacíos de TotalCharges eran clientes nuevos (antigüedad = 0) → se imputaron en 0. Sin filas duplicadas.

Variables nuevas: cómo se construyen y qué resumen

VARIABLE CREADA #1

Contrato mensual

is_month_to_month = 1 si Contract es “Month-to-month”; 0 si el contrato es anual o bianual.

VARIABLE CREADA #2

Fibra óptica


has_fiber_optic = 1 si InternetService es “Fiber optic”; 0 para DSL o sin internet.

OTRAS VARIABLES DERIVADAS

Antigüedad en 5 tramos · gasto histórico mensual y brecha de cargos · conteos de soporte, streaming y servicios · señales de pago digital

Estas features no agregan información futura: reorganizan datos disponibles al momento de predecir.

Principales hallazgos del EDA respecto del churn



LECTURA

Cheque electrónico y contrato mensual concentran tasas cercanas al 45%.

Fibra y ausencia de soporte o seguridad superan la media general.

El contrato a 2 años presenta el churn más bajo: 2,8%.

Son asociaciones; orientan hipótesis, no prueban causalidad.

Con clases desbalanceadas: PR-AUC compara y F2 define el corte

PR-AUC

¿Qué tan bien ordena el riesgo?

Churn es la clase minoritaria (26,5%).
Se busca evaluar específicamente qué tan bien el modelo identifica y prioriza esa clase, equilibrando recall y precisión para todos los umbrales.
Por eso es la métrica principal para comparar modelos.

Uso: comparar modelos bajo la misma validación cruzada.

F2

¿Dónde conviene cortar el ranking?

En retención, un falso negativo es un cliente que se va sin recibir una acción; implica perder ingreso recurrente. Un falso positivo genera un contacto u oferta posiblemente innecesaria, normalmente menos costosa. Por eso priorizamos recall; F2 le da 4 veces más peso sin ignorar precisión.

Uso: elegir el umbral operativo dentro de train.

Validación confiable: estratificación, CV y test cerrado

PARTICIÓN

80% train · 20% test

Split estratificado: conserva aproximadamente 26,5% de churn en ambos conjuntos. Evita que una partición azarosa distorsione la comparación.

Seed 42 · test usado una sola vez

VALIDACIÓN CRUZADA

5 folds dentro de train

Cada combinación entrena en 4 folds y valida en el restante; el proceso rota cinco veces. Se promedian los resultados para comparar modelos e hiperparámetros con menor dependencia de un único corte.

Misma métrica: PR-AUC

SIN LEAKAGE

El test no informa decisiones

Imputación, escalado y one-hot se ajustan dentro de cada fold. customerID queda excluido y el umbral F2 se elige con validación interna, nunca mirando el test final.

0 clientes solapados train / test

Regresión logística: baseline simple, fuerte e interpretable

BASELINE REAL

Regresión logística

35 variables predictoras

19 originales + 16 derivadas; tras one-hot se expanden a 65 columnas.

Regularización L2 · C = 3,0

POR QUÉ SE ELIGE COMO BASELINE

Es el estándar simple para clasificación binaria y entrega probabilidades de churn.

Es rápida, reproducible e interpretable: sus coeficientes muestran dirección y peso.

La regularización L2 penaliza coeficientes grandes y reduce el riesgo de sobreajuste.

Usa el mismo pipeline, variables y folds: la comparación es justa.

— Supera al Dummy y alcanza PR-AUC CV = 0,660.


PISO

Dummy

PR-AUC 0,265

Solo representa la prevalencia. Sirve para comprobar que el baseline aprende señal real.

10 modelos comparados por PR-AUC en validación cruzada



Los modelos lineales y de boosting concentran el mejor desempeño. Las diferencias superiores son pequeñas: importa validar estabilidad, no solo el ranking puntual.

Los métodos más complejos no garantizan una mejora material. La elección debe equilibrar desempeño, interpretabilidad, costo y mantenimiento.

CatBoost — hiperparámetros y desempeño en test

CatBoost es un boosting de árboles: cada árbol corrige errores de los anteriores y el conjunto estima la probabilidad de churn.

0,664

PR-AUC
ranking

90,9%

RECALL
churn detect.

42,4%

PRECISION
contactos útiles

0,740

F2
umbral 0,31

Hiperparámetros (GridSearch)

depth = 4

iterations = 100


learning_rate = 0.05

l2_leaf_reg = 3

Brecha train-test baja (+0,02 en F2) y sin leakage:
ID excluido, 0 solapamiento train/test, umbral fuera del test.

	Predijo: No	Predijo: Churn
Real: No	574 Verdadero neg.	461 Falso positivo
Real: Churn	34 Falso negativo	340 Verdadero pos.

El umbral 0,31 prioriza detectar a los que se van



Con umbral 0,31 se captura el 91% de los churners (recall alto).


El costo son más falsos positivos: la precisión baja a ~42%.

Decisión de negocio: mejor sobre-contactar que perder a un cliente.

Probabilidad $\geq 0,31$: Se predice churn y se considera al cliente para una acción de retención.

Probabilidad $< 0,31$: Se predice que permanecerá.

SHAP confirma el EDA y agrega una lectura multivariable




SHAP muestra cuánto aporta cada variable a las predicciones del modelo.

Coincide con el EDA: contrato mensual, baja antigüedad, fibra y falta de soporte/seguridad vuelven a dominar.

El modelo agrega matices: cargos acumulados y combinaciones entre variables ganan relevancia al analizarlas juntas.

Coincidencia no implica causalidad; SHAP explica predicciones, no el motivo real de la baja.

El modelo prioriza; negocio personaliza la intervención



DEL SCORE A UNA ACCIÓN CONCRETA

RIESGO ALTO: ATENCION PRIORITARIA

Score + valor del cliente definen el orden de contacto.

SHAP: EJEMPLOS DE ACCION

SHAP permite ver qué variables influyeron en el riesgo de cada cliente. La empresa adapta la intervención según esas señales

RIESGO BAJO: NO SOBREINCENTIVAR

Monitorear y reservar descuentos para clientes con riesgo y valor suficientes.

MEDIR: ACCIONES FUNCIONAN?

Grupo de control · churn evitado · costo por retención · margen incremental

Qué falta para llevarlo a una decisión productiva

Limitaciones

- Dataset sin dimensión temporal: no simula pasado → futuro.
- No hay costos reales de contacto, oferta ni valor del cliente.
- Precisión moderada: muchos contactos no terminarían en churn.
- Variables derivadas algo redundantes con las originales.

Mejoras

- Validar con meses futuros y monitorear drift.
- Elegir umbral por valor esperado ($\text{prob} \times \text{valor} \times \text{costo}$).
- Sumar tickets, NPS, uso del servicio y promociones.
- Calibrar probabilidades para usar el score como ranking.

11 • CONCLUSIÓN

Un ranking accionable para priorizar la retención

- Transformamos el problema de negocio en un modelo reproducible.
- CatBoost ordena a los clientes activos por riesgo de baja.
- Perfil de alto riesgo: contrato mensual, poca antigüedad, fibra, pocos servicios.
- Acción: contactar primero a los de mayor score con permanencia, soporte o beneficios.

CatBoost

MEJOR PR-AUC

0,664

PR-AUC TEST

90,9%

RECALL

Antes de producción: definir costo de acción, capacidad y umbral por rentabilidad esperada.